

Réseaux bancaires et contagion

Simuler une crise, prédire son ampleur, évaluer une intervention

Séances d'encadrement 25 septembre ; 7, 9 et 23 octobre

Encadrement Dr. Mario Veruete – Coruscant / Willing Technologies

1 Votre mission

Une crise peut (aussi) se transmettre par les relations financières

Des banques se prêtent de l'argent. Lorsqu'une banque ne rembourse plus ses dettes, ses créanciers subissent des pertes. Si ces pertes dépassent leur capacité à les absorber, ils peuvent à leur tour faire défaut : c'est une **cascade de défauts**. Le risque dépend donc (aussi) des relations entre les établissements.

Une cellule de supervision souhaite repérer les situations les plus fragiles et comparer des façons de renforcer le système avec un budget limité.

Votre équipe sera chargée d'étudier plusieurs **réseaux bancaires fictifs**.

Votre objectif est de répondre à la question suivante :

À partir de la structure d'un réseau (un graphe, au sens de la théorie des graphes) et des caractéristiques des banques, peut-on prévoir l'ampleur d'une cascade de défauts et proposer une intervention qui en réduit les conséquences ?

Je vous suggère de procéder en quatre étapes

1. **Décrire** le réseau et repérer des banques potentiellement influentes ou fragiles.
2. **Simuler** la propagation d'un défaut avec une règle commune à toutes les équipes.
3. **Apprendre à prédire** la proportion de défauts secondaires grâce à un modèle simple de machine learning.
4. **Comparer** une intervention ciblée à une intervention aléatoire, à budget identique, puis expliquer vos résultats.

Connaissances nécessaires

Vous devez pouvoir manipuler un tableau avec **pandas**, écrire une fonction et une boucle en Python, produire un graphique et interpréter une moyenne. Connaissances de base sur la régression.

Les notions de graphe orienté, de cascade, d'apprentissage supervisé et d'évaluation seront introduites ou rappelées pendant l'accompagnement. Aucune connaissance préalable de la réglementation bancaire n'est requise.

Le résultat attendu est une étude reproductible et argumentée, appuyée sur quelques figures lisibles. Le simulateur représente un mécanisme pédagogique simplifié ; les résultats ne constituent pas des prévisions sur des banques réelles.

2 Descriptif des données

Jeu de données

Le **kit de départ fourni avec ce sujet** contient : un jeu de données principal, un dictionnaire des variables et un exemple à trois banques. Vous travaillerez sur les fichiers remis ; aucune autre donnée n'est nécessaire.

Le jeu de données principal comprend **12 réseaux indépendants de 60 banques**. Ils présentent des structures et des niveaux de fragilité variés. Tous les montants sont exprimés dans une même unité monétaire fictive. Un second exemple, **RELAIS**, illustre une intervention sur 12 banques. Les deux exemples sont exclus de l'apprentissage, de la validation et du test.

Fichier	Contenu et colonnes
banques.csv	Une ligne par banque et par réseau : <code>reseau_id</code> , <code>banque_id</code> , <code>capital</code> . Le capital est strictement positif.
expositions.csv	Une ligne par dette : <code>reseau_id</code> , <code>debiteur_id</code> , <code>creancier_id</code> , <code>montant</code> . Les montants sont strictement positifs.
repartition.csv	Une ligne par réseau : <code>reseau_id</code> , <code>usage</code> , avec les valeurs <code>apprentissage</code> , <code>validation</code> ou <code>test</code> .

Bien lire le sens d'une relation

Chaque banque est un sommet du graphe. Une arête orientée $i \rightarrow j$, de poids e_{ij} , signifie que **la banque i doit le montant e_{ij} à la banque j** . Si i fait défaut, c'est donc j qui risque de perdre de l'argent. L'orientation choisie suit le sens de propagation des pertes.

Le capital c_j est le montant de pertes que la banque j peut absorber. Dans ce modèle, une banque fait défaut lorsque ses pertes **dépassent strictement** son capital. Une perte exactement égale au capital ne déclenche pas de défaut.

Exemple

La banque A doit 10 à B ; B doit 8 à C. Les capitaux de B et de C sont respectivement 4 et 3. Supposons que la moitié d'une dette soit perdue en cas de défaut. Si A fait défaut, B perd $0,5 \times 10 = 5$, ce qui dépasse son capital de 4. B fait donc défaut à son tour. C perd ensuite $0,5 \times 8 = 4$, ce qui dépasse son capital de 3 : la cascade atteint les trois banques.

Points de contrôle

Vérifiez l'unicité des banques dans chaque réseau, l'absence de valeurs manquantes, la positivité des montants et l'existence des deux banques de chaque relation. Le jeu fourni ne doit contenir ni dette d'une banque envers elle-même, ni doublon d'une même paire orientée. Conservez aussi les banques isolées lors de la construction du graphe.

Les données décrivent uniquement les dettes entre banques et leur capacité d'absorption des pertes. Elles ne représentent pas des bilans comptables complets.

3 Explorer le réseau bancaire et simuler une cascade de défauts

Étape 1 : formuler des hypothèses à partir du graphe

Construisez un graphe orienté pondéré avec `NetworkX`. Pour au moins un réseau d'apprentissage, présentez le nombre de banques et de relations, puis une visualisation lisible d'un sous-réseau ou du réseau complet.

Calculez les degrés entrants et sortants, ainsi que les sommes des poids entrants et sortants. Interprétez-les avec la convention de la section 2 : le poids entrant mesure les créances détenues ; le poids sortant mesure les dettes envers les autres banques. Proposez deux hypothèses, par exemple : une banque ayant de nombreux créanciers propage-t-elle davantage de défauts ?

Étape 2 : appliquer la règle de propagation

Un scénario est défini par un réseau, une banque initialement défaillante s et une fraction de perte λ , comprise entre 0 et 1. Cette fraction est identique pour toutes les dettes du scénario. Le choc initial impose le défaut de s , quel que soit son capital.

On note D_t l'ensemble des banques ayant fait défaut à l'étape t . À partir de $D_0 = \{s\}$, calculez :

$$L_j(D_t) = \lambda \sum_{i \in D_t} e_{ij}, \quad D_{t+1} = D_t \cup \{j \notin D_t : L_j(D_t) > c_j\}.$$

Une dette absente vaut zéro. Tous les nouveaux défauts d'une étape sont ajoutés **simultanément**. La simulation s'arrête lorsque l'ensemble des banques défaillantes ne change plus. Un défaut est irréversible.

Attention au cumul : $L_j(D_t)$ est la perte totale associée aux banques déjà défaillantes. Ne l'ajoutez pas à nouveau aux pertes de l'étape précédente, sinon les mêmes dettes seraient comptées plusieurs fois.

Les résultats à conserver

Pour chaque scénario, enregistrez la banque d'origine, λ , l'ensemble final des défauts et le nombre de nouveaux défauts à chaque étape. La mesure principale est la **proportion de défauts secondaires** :

$$y = \frac{|D_{\text{final}}| - 1}{N - 1}, \quad N = \text{nombre de banques}.$$

Dans les réseaux principaux, $N = 60$. La valeur $y = 0$ signifie que le choc reste limité à la banque d'origine ; $y = 1$ signifie que toutes les autres banques font défaut.

Quelques vérifications indispensables

Retrouvez le résultat de l'exemple A–B–C. Vérifiez aussi qu'il n'y a aucun défaut secondaire lorsque $\lambda = 0$, lorsque le réseau n'a aucune arête, ou lorsque tous les capitaux dépassent les pertes possibles. Testez le cas limite d'une perte égale au capital et le traitement simultané des défauts. Enfin, augmenter les capitaux ne doit pas augmenter la cascade, à réseau et choc initial identiques.

Piste de travail : utilisez deux ensembles, les défauts connus et les nouveaux défauts. Parcourez les débiteurs de chaque banque encore active, puis faites l'union des ensembles. Le fichier `verifier_simulateur.py` fournit neuf tests ; l'aide `depasse_capital` traite les arrondis numériques.

Ce modèle est une cascade à seuil : il ne modélise ni les paiements partiels successifs, ni les ventes d'actifs, ni les réactions des marchés.

4 Ajoutez une composante de machine learning

Prédiction par régression

Votre modèle doit **prédire y avant de lancer la cascade**, à partir d'informations disponibles sur le réseau initial. Il sert à approcher le résultat du simulateur. Il n'est pas demandé de prévoir une crise réelle ni de démontrer un gain de vitesse sur ces petits réseaux.

Construisez une table avec une ligne par triplet (**réseau, banque d'origine, fraction de perte**). Faites varier λ dans $\{0,3; 0,6; 0,9\}$ et utilisez successivement chaque banque comme origine : vous obtenez $12 \times 60 \times 3 = 2160$ scénarios sans intervention. Le simulateur fournit la cible y . L'aide `generer_scenarios` organise ces calculs à partir de vos fonctions.

Les variables explicatives

Utilisez au minimum λ , le capital de la banque d'origine, ses degrés entrant et sortant et les sommes de ses poids entrants et sortants. Vous pouvez ajouter **une ou deux variables motivées**, par exemple le nombre de banques atteignables en deux relations ou la fragilité moyenne des créanciers directs. Définissez précisément leur calcul. Le capital de l'origine peut être corrélé à d'autres caractéristiques, mais ne protège pas cette banque du défaut initial imposé.

Les identifiants servent au suivi et au partage des données, pas à la prédiction. Aucun résultat de la cascade, comme le nombre de défauts à la première étape, ne peut être utilisé comme variable explicative.

Un protocole commun pour comparer les résultats

1. **Respectez la répartition fournie** : 8 réseaux pour l'apprentissage, 2 pour la validation et 2 pour le test. Tous les scénarios d'un réseau restent dans le même ensemble. Un partage aléatoire des lignes ne testerait pas la capacité à traiter un nouveau réseau.
2. **Calculez deux références fournies** : la médiane globale des cibles d'apprentissage, puis une médiane distincte pour chaque valeur de λ . L'aide `references_medians` réalise ces deux calculs. La seconde référence permet d'isoler ce qu'apportent les variables du réseau au-delà de l'intensité du choc.
3. **Entraînez un modèle** : un arbre de régression ou une forêt aléatoire avec `scikit-learn`. Choisissez quelques réglages sur la validation, par exemple deux ou trois profondeurs. Un seul modèle appris suffit ; une recherche exhaustive n'est pas attendue.
4. **Évaluez une fois les choix arrêtés** : utilisez le test pour la comparaison finale avec les deux références. Les transformations éventuelles sont ajustées uniquement sur l'apprentissage ; aucun réglage ne doit dépendre des résultats du test.

Ce que vous devez analyser

Présentez l'erreur absolue moyenne $MAE = \frac{1}{m} \sum_{r=1}^m |y_r - \hat{y}_r|$, sur les m scénarios de test, globalement et par réseau. Une MAE de 0,05 représente une erreur moyenne de 5 points de pourcentage sur la proportion de défauts secondaires.

Ajoutez un graphique des prédictions face aux valeurs simulées et commentez au moins deux erreurs importantes. Présentez un histogramme de y , qui peut partager une figure avec ce graphique : les petites et grandes cascades ne sont pas nécessairement aussi fréquentes que les cascades intermédiaires.

Expliquez les variables utilisées et les limites de généralisation : deux réseaux de test issus d'un générateur restent une évaluation limitée. **Un gain de performance n'est pas garanti et n'est pas une condition de réussite du projet.**

5 Comparer des stratégies de protection

Une décision à budget identique

La cellule de supervision peut renforcer le capital de certaines banques **avant de connaître l'origine du choc**. Pour chaque réseau, le budget commun est $B = 0,10 \sum_j c_j$, calculé sur les capitaux initiaux. Il est réparti à parts égales entre $k = 5$ banques sélectionnées : chacune reçoit B/k . Les dettes et la règle de propagation restent identiques.

Comparez les trois situations suivantes :

1. **Sans intervention** : les capitaux initiaux sont conservés.
2. **Intervention aléatoire** : cinq banques distinctes sont tirées au sort, sans remise.
3. **Intervention ciblée** : cinq banques sont choisies selon une règle que vous justifiez à partir du réseau avant le choc.

Piste de départ : combinez la fragilité $v_j = \sum_i e_{ij}/c_j$ et le nombre de créanciers d_j^{sortant} , par exemple avec $s_j = v_j d_j^{\text{sortant}}$. L'idée est de protéger une banque susceptible de subir *et de transmettre* des pertes : une banque fragile sans créancier ne propage pas son propre défaut. Ce score n'est pas une solution optimale garantie. Vous pouvez choisir un autre critère motivé ; précisez le classement et le départage des égalités.

Une comparaison équitable

- Définissez votre règle sur les réseaux d'apprentissage et de validation, puis figez-la avant l'évaluation finale sur les réseaux de test.
- Pour un réseau, choisissez les banques renforcées une seule fois, avant les chocs, puis évaluez la stratégie sur les mêmes 60 origines et les mêmes trois valeurs de λ .
- Répétez dix fois la sélection aléatoire avec des graines fixées. Chaque sélection est évaluée sur tous les scénarios du réseau. Présentez la moyenne et la dispersion de ses résultats.
- Le défaut initial reste imposé, même si la banque d'origine a reçu du capital. Le renforcement agit sur la contagion secondaire.

Pour chaque stratégie, comparez la moyenne de y sur les scénarios et la plus grande cascade observée, puis détaillez les résultats par λ . Présentez le gain moyen par rapport à l'absence d'intervention en **points de pourcentage**. La moyenne sur les scénarios est un indicateur de comparaison ; elle n'est pas une probabilité de crise réelle.

Pour démarrer : l'exemple RELAIS, expliqué dans les fiches, montre comment protéger une banque intermédiaire peut arrêter une cascade. Les aides `capitaux_renforces` et `comparer_interventions` prennent en charge le budget et les répétitions, à partir de votre simulateur.

Votre marge de liberté

Choisissez vos visualisations, vos variables supplémentaires, votre modèle parmi les méthodes proposées et votre règle de ciblage. Le socle obligatoire suffit pour obtenir l'ensemble des points. Une fois ce socle terminé, vous pouvez explorer **un seul prolongement** : faire varier le budget, comparer un second modèle de régression, ou tester une autre structure de réseau. Une interface

interactive est facultative.

Une banque dont le défaut est très contagieux n'est pas nécessairement celle qu'il faut renforcer en priorité : discutez la différence entre **prédire un risque** et **mesurer l'effet d'une intervention**. L'efficacité des stratégies est toujours vérifiée avec le simulateur.

6 Le programme d'accompagnement

Le travail avance pendant les séances, en équipe, avec des points de validation. Les tâches entre les rencontres sont courtes et ciblées. Le calendrier ci-dessous prévoit un lancement de trois heures le 25 septembre, à ajuster au créneau disponible.

25 septembre : comprendre le sujet et démarrer

Objectif : comprendre la mission et disposer d'un premier résultat. La séance comprend la présentation détaillée du contexte, des objectifs, des rendus et de l'évaluation (environ 30 minutes), puis un repérage rapide des acquis et des rappels adaptés (environ 60 minutes) : graphes orientés, pertes et capital, cascade à seuil, principes de la régression et partage apprentissage-validation-test.

Un atelier accompagné d'environ 90 minutes permet de charger les données, vérifier l'exemple à trois banques et commencer l'exploration. Une démonstration courte de RELAIS donne le sens de l'intervention. Les tests et les aides Python sont disponibles dès cette séance.

Jalon : chaque équipe exécute le chargement, explique le sens des liens et dispose d'une première figure.

D'ici au 7 octobre : terminer les premiers contrôles et noter au plus trois questions ou blocages. Temps autonome visé : 1 heure.

7 octobre, matin : déblocage personnalisé et simulation

La matinée est consacrée au travail en équipe et à un entretien d'environ 15 minutes avec chaque groupe. Vous montrez un résultat, un blocage reproductible et votre prochaine étape. L'encadrant aide à corriger la lecture du graphe, la propagation ou l'organisation du travail.

Jalon : le simulateur passe les vérifications simples ; la table de scénarios est lancée ou disponible. Si le simulateur bloque encore, l'encadrant remet la table de secours d'apprentissage et de validation ; le simulateur reste à expliquer et à corriger. Les résultats de secours du test sont remis après fixation des choix. **D'ici au 9 octobre :** vérifier cette table et préparer les variables explicatives. Temps autonome visé : 1 heure.

9 octobre, matin : apprendre, évaluer et débloquer

Selon les besoins observés le 7, un complément technique collectif d'au plus 45 minutes porte sur les arbres et forêts, la MAE, les fuites de données ou la comparaison des interventions. La suite de la matinée alterne travail des groupes et aide individualisée.

Jalon : les deux références fournies et un modèle appris sont évalués sur la validation ; un premier essai d'intervention fonctionne. **D'ici au 23 octobre :** figer les choix, lancer les comparaisons finales et préparer les figures et les diapositives. Temps autonome visé : 2 heures.

23 octobre, matin : corriger et valider les productions

L'encadrant accompagne les derniers correctifs et vérifie avec chaque groupe l'exécution complète, la cohérence des résultats et la lisibilité des conclusions. Les équipes finalisent leurs supports. **Jalon :** le projet et la présentation sont remis en fin de matinée.

23 octobre, après-midi : restitution proposée, à confirmer. Prévoir 8 minutes de présentation et 4 minutes d'échange par équipe. Chaque membre doit pouvoir expliquer une partie de la démarche.

Charge cible : environ 12 heures en séances accompagnées et 4 heures de travail autonome par étudiant, réparties en trois créneaux d'équipe. La restitution s'ajoute à ce volume. En cas de retard, l'encadrant fournit une aide ciblée ou une table intermédiaire et supprime les prolongements pour préserver cette charge.

7 Les rendus et les critères d'évaluation

Un rendu compact, entièrement réexécutable

Remettez un dossier ou un dépôt partagé contenant :

- **Le travail Python** : un notebook structuré, exécutable du début à la fin, accompagné de quelques fonctions dans des fichiers `.py` si cela simplifie la lecture. Un projet uniquement en scripts convient également.
- **Un court fichier de présentation** : auteurs, instructions d'exécution, dépendances, graines aléatoires et hypothèses. Il indique aussi les aides ou ressources externes utilisées.
- **Les résultats** : une visualisation de réseau, une courbe de cascade, la distribution des cibles et la comparaison des prédictions aux valeurs simulées, et un tableau ou graphique comparant les interventions.
- **Cinq à six diapositives** : question étudiée, méthode, principaux résultats, recommandation et limites. Aucun rapport supplémentaire n'est demandé.

Utilisez des noms explicites, quelques fonctions réutilisables et les vérifications de la section 3. Une architecture logicielle complexe, un déploiement et un tableau de bord ne sont pas exigés. Chaque membre doit participer à l'analyse et comprendre les choix principaux du projet.

Grille d'évaluation proposée

Critère	Poids	Ce qui est évalué
Données et réseau	15 %	Contrôles, orientation des liens, indicateurs interprétés.
Simulation	25 %	Règle correcte, cas simples vérifiés, résultats cohérents.
Machine learning	25 %	Cible et variables pertinentes, référence, partage par réseau, évaluation et analyse des erreurs.
Intervention et analyse	20 %	Budget identique, comparaison équitable, conclusion argumentée et limites explicites.
Reproductibilité et présentation	15 %	Exécution complète, figures lisibles, présentation claire et compréhension collective.

La qualité du raisonnement compte davantage que le nombre de modèles ou d'options. Une stratégie ciblée peut être peu efficace ; une conclusion négative correctement établie est un résultat recevable. Les prolongements facultatifs ne donnent pas de points supplémentaires.

Quelques ressources pour le travail

En complément des supports remis pendant les séances :

- **NetworkX** : graphes, sommets, arêtes et attributs.
- **scikit-learn** : arbres de décision et régression.
- **scikit-learn** : mesures d'évaluation et modèles de référence.
- **scikit-learn** : bonnes pratiques et prévention des fuites de données.